

Unidad I: Fundamentos de Estadística Aplicada a Datos Masivos

Introducción a la estadística en ciencia de datos.

Diferencia entre estadística descriptiva e inferencial.

Conceptos de muestra, población y sesgo en la recolección de datos.

Estadística descriptiva aplicada a Big Data: Tipos de variables: discretas y continuas.

Medidas de tendencia central (media, mediana, moda).

Medidas de dispersión (varianza, desviación estándar, rango intercuartil).

Histogramas, boxplots y visualización de distribuciones.

Distribuciones de probabilidad y su aplicación en ciencia de datos: Distribución normal, binomial, de Poisson y exponencial.

Sumas de variables aleatorias y teorema central del límite.

Modelos probabilísticos aplicados a predicción y machine learning.

Análisis de correlación y regresión: Correlación de Pearson y Spearman.


Regresión lineal simple y múltiple.

Aplicaciones en modelado predictivo y econometría.

Desarrollo

Introducción a la estadística en Ciencia de Datos

Análisis exploratorio de datos



La estadística clásica se ocupó casi de manera exclusiva de la inferencia, es decir un conjunto de procedimientos, a veces complejos, para sacar conclusiones sobre grandes poblaciones a partir de muestras de pequeño tamaño.

El análisis de datos o “data analysis”, surge posteriormente, en 1962, John Tukey, pionero en la ciencia de datos, propone una nueva disciplina científica que incluía la inferencia estadística como un componente más.

Entonces forjó vínculos con los colectivos de profesionales de distintas áreas, acuñó términos que ocupamos hoy como **bit o software** y presentó diagramas sencillos junto a resúmenes estadísticos, de manera de tener una imagen nítida del conjunto de datos.

Un desafío importante de la ciencia de datos es convertir el **caudal de datos sin procesar en información útil**.

Los datos en bruto, no estructurado, deben procesarse y manejarse en un formato estructurado. Una de las formas más habituales en las que se presentan los datos estructurados son tablas, con filas y columnas. Bien porque los datos pueden proceder de una base de datos relacional o porque los recopilamos así para su estudio.

La estadística descriptiva es la rama de la estadística que se ocupa de resumir y describir las características principales de un conjunto de datos. Su objetivo es presentar la información de manera clara y concisa, utilizando tablas, gráficos y medidas numéricas para facilitar su comprensión. No busca hacer inferencias, sino describir lo que observa con los datos recopilados.

Población: Es el conjunto completo de elementos sobre los que queremos obtener información. Incluye a todos los individuos, objetos o eventos que cumplieron con cierta característica. A veces es muy grande y no siempre podemos medirlo completo.

Por ejemplo:

- Todos los habitantes de Argentina, con el censo una vez cada diez años.
- Todos los autos fabricados en 2024 por una marca o por todas las marcas
- Todos los estudiantes de una universidad o de todas las universidades


Es necesario para delimitar una Población definir el problema a investigar, los objetivos de la investigación e identificar qué o quiénes van a ser medidos:

Unidad de Análisis = Individuos = Elementos

Muestra: es un subconjunto representativo de la población que elegimos para estudiar. Se utiliza porque analizar toda la población es costoso e imposible. Para que sea útil, debe representar bien a la población.

Por ejemplo:

- Encuesta permanente de hogares
- 50 autos elegidos al azar para control de calidad en una marca
- 200 estudiantes de una universidad para una encuesta de hábitos de estudio




Sesgo en la recolección de datos: el sesgo aparece cuando los datos no representan correctamente a la población. Sucede por errores en cómo se elige la muestra o cómo se hace la medición. El resultado es engañoso y puede llevar a conclusiones incorrectas.


Por ejemplo:

- **Sesgo de selección:** hacer una encuesta por Internet, deja afuera a quienes no tienen acceso, distorsionando los resultados.
- **Sesgo de no respuesta:** si muchas personas no contestan la encuesta, los resultados pueden no reflejar la realidad.
- **Sesgo del entrevistador:** si el encuestador influye en la respuesta con su forma de preguntar

Sesgo es una manera de mirar el mundo con anteojos distorsionados, no todo lo que ves, es la realidad, o lo que ves es una parte de la realidad.



Hay dos tipos de datos estructurados: numéricos y categóricos.



Modalidades básicas de los datos estructurados

Datos numéricos

Son aquellos que se pueden medir o calcular.

Permiten realizar operaciones como sumar, restar, promediar, etc.

Miden magnitudes, como peso, edad, altura, temperatura, ingresos, etc.

1. **De carácter continuo**, como por ejemplo la velocidad del viento, duración del tiempo, etc.

Son números con decimales, se obtienen midiendo, admiten cualquier valor en un rango

Ejemplo:

- Datos físicos de una persona: peso 63.5 Kg, altura 1.72 mts,
- Tiempo de una carrera: 12.38 segundos
- Ingresos familiares: \$ 231.453,31

2. **De carácter discreto**, como el recuento de las veces que ocurre un evento.

Son números enteros, se obtienen contando y no admiten decimales

Ejemplo:

- Cantidad de hijos
- Autos en una familia,
- Goles en un partido

Datos categóricos

Son aquellos que representan categorías o grupos, no cantidades numéricas que podamos sumar o restar.

Sirven para clasificar o etiquetar elementos, pero no tienen un valor numérico intrínseco, aunque a veces los codifiquemos con números para analizarlos en la computadora.

1. **Ordinales**, adoptan un conjunto fijo de valores que sí tienen un orden. No hay distancia numérica exacta entre categorías, pero podemos decir cuál está antes o después.

Ejemplo:

- tamaño de la ropa → S, M, L, XL
- Nivel de satisfacción → Bajo, Medio, Alto
- Puestos en una carrera → 1°, 2°, 3°

2. **Nominales**, adoptan solo uno de dos valores (binarios)

- a. 0/1
- b. Sí/No
- c. Verdadero/Falso

La identificación explícita de datos como categóricos, como algo diferente al texto, ofrece ventajas:

- Saber que son categóricos sirve de señal para indicarle al software como deben comportarse los procedimientos estadísticos, como crear un gráfico o ajustar un modelo.
- El almacenamiento y la indexación se pueden optimizar, como en una base de datos relacional.
- Los posibles valores que puede adoptar una variable categórica dada, se aplican al software, como puede pasar en una enumeración.
- Procesos de conversión de archivos de csv o texto a columnas

En la actualidad, las tecnologías y herramientas de Big Data se deben centrar en la **integración de datos estructurados y datos no estructurados o semiestructurados**, así como la integración de los **datos tradicionales en las bases de datos relacionales con los datos no estructurados en las bases de datos analíticas y NoSQL**. Otro aspecto fundamental es el tema de la seguridad y la privacidad de los grandes volúmenes de datos.

BIG DATA

Según Adrian Merv, 2011:

“Big Data excede el alcance de los entornos de hardware de uso común y herramientas de software para capturar, gestionar y procesar los datos dentro de un tiempo transcurrido tolerable para su población de usuarios”

Según McKinsey Global Institute, 2011:

“Big Data se refiere a los conjuntos de datos cuyo tamaño está más allá de las capacidades de las herramientas típicas de software de bases de datos para capturar, almacenar, gestionar y analizar”

Según consultora tecnológica IDC:

“Big Data es una nueva generación de tecnologías, arquitecturas y estrategias diseñadas para capturar y analizar grandes volúmenes de datos provenientes de múltiples fuentes heterogéneas a una alta velocidad con el objeto de extraer valor económico de ellos”

Según la empresa multinacional de auditoría Deloitte:

“El término que se aplica a conjuntos de datos cuyo volumen supera la capacidad de las herramientas informáticas (computación) de uso común, para capturar, gestionar y procesar datos en un lapso de tiempo razonable. Los volúmenes de Big Data varían constantemente, y actualmente oscilan entre algunas decenas de terabytes hasta muchos petabytes para un conjunto de datos individual”

Entonces, la definición puede variar según las características de las empresas.

Para unas empresas prima el volumen; para otras, la velocidad; para otras, la variabilidad de las fuentes. Las empresas con mucho volumen o volumetría van a estar interesadas en capturar la información, guardarla, actualizarla e incorporarla en sus procesos de negocio; pero hay empresas que, aunque tengan mucho volumen, no necesitan almacenar, sino trabajar en tiempo real y a gran velocidad. Otras, por el contrario, pueden estar interesadas en gestionar diferentes tipos de datos.

Medidas de tendencia central (media, mediana, moda).

Las medidas de tendencia central resumen un conjunto de datos indicando su centro o valor típico

Media: El promedio aritmético de todos los valores (suma de valores / número de valores)

Si tenemos una muestra de n observaciones y denotadas por $X_1, X_2, \dots, X_n$, definimos la *media muestral* $\bar{X}$ del siguiente modo:

$$\bar{X} = \frac{X_1 + X_2 + \dots + X_n}{n} = \frac{\sum_{i=1}^n X_i}{n}$$

El símbolo $\sum_{i=1}^n X_i$ indica la suma de todos los valores observados de la variable desde el primero ($i = 1$) hasta el último ($i = n$).

Mediana: El valor central en un conjunto de datos ordenado; el 50% de los datos son menores o iguales a ella, y el 50% son mayores o iguales



¿Cómo calculamos la mediana de una muestra de n observaciones?

1. Ordenamos los datos de menor a mayor.
2. La mediana es el dato que ocupa la posición $\left(\frac{n+1}{2}\right)$ en la lista ordenada.

Si el número de datos es *impar*, la mediana $\bar{X}$ es el dato que ocupa la posición central.

Si el número de datos es *par*, la mediana $\bar{X}$ es el promedio de los dos datos centrales.

Ejemplo

- *n impar*

$X_1 = 10$ $X_2 = 14$ $X_3 = 12$ $X_4 = 18$ $X_5 = 11$

Ordenamos los datos:

10 11 12 14 18

La posición de la mediana es $\frac{n+1}{2} = \frac{5+1}{2} = 3$ (tercer dato), es decir $\bar{X} = 12$.

- *n par*

$X_1 = 10$ $X_2 = 14$ $X_3 = 12$ $X_4 = 18$ $X_5 = 11$ $X_6 = 23$

Ordenamos los datos:

10 11 12 14 18 23

Posición de la mediana $\Rightarrow \frac{6+1}{2} = 3.5$

Obtenemos la mediana promediando el tercer y cuarto dato: $\bar{X} = \frac{12+14}{2} = 13$.

Notar que $(n+1)/2$ no es la mediana, sino la localización de la mediana en el conjunto ordenado de datos.

Si hay datos repetidos deben ser incluidos en el ordenamiento.

La mediana es muy simple de obtener a partir de un gráfico de tallo-hojas.

Moda: El valor que aparece con mayor frecuencia en el conjunto de datos; puede haber una o más modas

$$Mo = L_{i-1} + a \cdot \frac{D_1}{D_1 + D_2}; \text{ siendo:}$$

L_{i-1} = Límite inferior del intervalo modal

a = Amplitud de los intervalos

D_1 = Diferencia de la frecuencia absoluta entre
Intervalo modal y el anterior

D_2 = Diferencia de la frecuencia absoluta entre
Intervalo modal y la siguiente

Medidas de dispersión (varianza, desviación estándar, rango intercuartil).

Las medidas de dispersión describen la variabilidad de los datos alrededor de ese centro.

Rango o rango de variación: La diferencia entre el valor máximo y el valor mínimo de los datos

Varianza: La medida de dispersión más utilizada, es el promedio de los cuadrados de las desviaciones con respecto a la media. Se representa como σ^2 para poblaciones y s^2 para muestras

Desviación estándar: La raíz cuadrada de la varianza, indica la dispersión de los datos alrededor de la media. Se representa como σ para poblaciones y s para muestras

VARIANZA	DESVIACIÓN ESTÁNDAR
$\sigma^2 = \frac{\sum_1^N (x_i - \bar{X})^2}{N}$	$\sigma = \sqrt{\frac{\sum_1^N (x_i - \bar{X})^2}{N}}$
• X → Variable sobre la que se pretenden calcular la varianza. • x_i → Observación número i de la variable X. i puede tomará valores entre 1 y n. • N → Número de observaciones. • $\bar{X}$ → Es la media de la variable X.	
RANGO ESTADÍSTICO	COEFICIENTE DE VARIACIÓN
$R = Máx_x - Mín_x$	$CV = \frac{\sigma_x}{ \bar{X} }$
• R → Es el rango. • Máx → Es el valor máximo de la muestra o población. • Mín → Es el valor mínimo de la muestra o población estadística. • x → Es la variable sobre la que se pretende calcular esta medida.	• X → Variable sobre la que se pretenden calcular la varianza. • σ_x → Desviación típica de la variable X. • $\bar{X}$ → Es la media de la variable X en valor absoluto con $\bar{x} \neq 0$.

Rango intercuartil: La diferencia entre el tercer cuartil (Q3) y el primer cuartil (Q1); mide la dispersión de los datos centrales

Ejemplo

Consideremos nuevamente los datos siguientes.

Posición	1	2	3	4	5	6	7	8	9	10	11	12	13
Datos	104	112	134	146	155	168	170	195	246	302	338	412	678

$$\text{Posición del Cuartil Inferior} = (13+1)/4 = 3.5 \Rightarrow C_1 = \frac{134+146}{2} = 140$$

$$\text{Posición del Cuartil Superior} = 3 \cdot (13+1)/4 = 10.5 \Rightarrow C_3 = \frac{302+338}{2} = 320$$

$$D_I = C_3 - C_1 = 320 - 140 = 80$$

Concluimos que el 50% central de los datos se encuentra en una distancia de 80 unidades.

Para estos datos $s = 160.5$. Si la distribución fuera simétrica esperaríamos que $D_I \cong 0.75 s = 0.75 \cdot 160.5 = 120$. Sin embargo, $D_I = 80$, lo que nos indica que la distribución es asimétrica.

Histogramas, boxplots y visualización de distribuciones.

Son herramientas visuales para comprender la distribución de los datos, mostrando su forma, centro y dispersión.

Histogramas: Representan la frecuencia de los datos en intervalos (barras), mostrando la forma de la distribución

Boxplots: (diagramas de caja y bigotes): Muestran la mediana, los cuartiles, el rango intercuartil y los valores atípicos, proporcionando una visión rápida de la dispersión y la simetría de los datos.

Ejemplo

Consideremos nuevamente los datos siguientes.

Posición	1	2	3	4	5	6	7	8	9	10	11	12	13
Datos	104	112	134	146	155	168	170	195	246	302	338	412	678

De los ejemplos anteriores sabemos que:

$$C_1 = 140 \quad \bar{X} = 170 \quad C_3 = 320 \quad D_1 = 320 - 140 = 80$$

Calculamos las cotas:


$$2^{\text{a}} \text{ cota inferior} = C_1 - 3 D_1 = 140 - 3 \cdot 80 = -100$$

$$1^{\text{a}} \text{ cota inferior} = C_1 - 1.5 D_1 = 140 - 1.5 \cdot 80 = 20$$

$$1^{\text{a}} \text{ cota superior} = C_3 + 1.5 D_1 = 320 + 1.5 \cdot 80 = 440$$

$$2^{\text{a}} \text{ cota superior} = C_3 + 3 D_1 = 320 + 3 \cdot 80 = 580$$

El gráfico de caja resultante se muestra en la figura siguiente.



Ramas de la estadística

La estadística se divide en dos grandes áreas:

ESTADÍSTICA DESCRIPTIVA

Es la rama de la estadística que se dedica a describir las características de un conjunto de datos (muestra o censo)

Analiza a través de:

- ✓ Cálculo de medidas de resumen
- ✓ Clasificación y agrupamiento
- ✓ Representación gráfica
- ✓ Tablas estadísticas

ESTADÍSTICA INFERENCIAL

Conjunto de técnicas que:

A partir de datos de una muestra infieren parámetros a una población

- ✓ Se basan en la Teoría de Probabilidad
- ✓ Realizan estimaciones de parámetros
- ✓ Identifican relaciones entre variables
- ✓ Descubren patrones en los datos
- ✓ Construyen modelos predictivos

Siempre teniendo en cuenta la aleatoriedad de las observaciones.

Distribuciones de probabilidad y su aplicación en ciencia de datos:

Las distribuciones de probabilidad describen **cómo se comporta una variable aleatoria**:


Variable aleatoria: Valor que surge al azar de un experimento o proceso.

Distribución: Indica la probabilidad de cada valor posible.

Principales distribuciones

1. Distribución normal o Gaussiana

Forma: Campana simétrica.



Ejemplo en datos: Altura de personas, errores de medición.

Propiedades clave:


- Media (μ) y desviación estándar (σ) definen la curva.
- ~68% de los datos están a 1σ de la media, ~95% a 2σ .

Aplicación en ciencia de datos:

- Detección de valores atípicos.
- Supuestos de muchos algoritmos estadísticos.

2. Distribución Binomial

Tipo: Discreta.



Situación: Experimentos con dos resultados (“éxito” o “fracaso”) repetidos n veces.

Ejemplo: Cantidad de clics en un anuncio (éxito = clic, fracaso = no clic).

Parámetros:


- n = número de intentos
- p = probabilidad de éxito

Aplicación:

- Modelar tasas de conversión en marketing digital.
- Evaluar rendimiento de pruebas A/B.

3. Distribución de Poisson

Tipo: Discreta.



Situación: Conteo de eventos raros en un intervalo fijo de tiempo o espacio.

Ejemplo:

- Cantidad de mails que llegan en una hora.
- Fallas en un servidor por día.

Parámetro:


- λ (lambda) = promedio de eventos por intervalo.

Aplicación en data Science:

- Modelos de demanda,
- Tráfico web,
- Incidentes de ciberseguridad.

4. Distribución Exponencial

Tipo: Continua.



Situación: Tiempo hasta que ocurra un evento (asociada a Poisson).

Ejemplo: Tiempo hasta la próxima llamada en un call center.

Parámetro:

- λ (tasa de eventos por unidad de tiempo).

Aplicación:

- Modelos de supervivencia.
- Predicción de fallos en sistemas.

Sumas de variables aleatorias y teorema central del límite.
Modelos probabilísticos aplicados a predicción y machine learning.

Sumas de Variables aleatorias y Teorema central del Límite (TCL)

Sumas de Variables aleatorias:

Es una función que asigna un valor numérico a cada resultado de un experimento aleatorio.

Por ejemplo

Número que sale al lanzar un dado (del 1 al 6)

Tiempo que tarda un alumno en completar un examen

Suma de variables aleatorias:

- Si tenemos $X_1, X_2, \dots, X_n$ variables aleatorias independientes, podemos construir:

$$S_n = X_1 + X_2 + \dots + X_n$$

- Aplicaciones comunes:
 - **Total de ventas** en una semana (suma diaria).
 - **Tiempo total de espera** en un sistema de colas.
 - **Suma de puntuaciones** en juegos de azar.

Comportamiento de las sumas:

- Si las variables son **idénticas e independientes (i.i.d.)**, la **media de la suma** es la suma de las medias y la **varianza** es la suma de las varianzas:

$$\begin{aligned} \mathbb{E}[S_n] &= n \cdot \mu \\ \text{Var}(S_n) &= n \cdot \sigma^2 \end{aligned}$$

Motivación práctica

- Muchas veces, **observamos fenómenos agregados**, como:
 - La **suma de errores de medición** en un experimento.
 - La **cantidad total de ventas** de un producto en un mes.
- Aunque **cada variable individual no sea normal**, la **suma o promedio suele aproximarse a una campana de Gauss**.
- Esto **simplifica el análisis estadístico**, porque podemos aplicar métodos basados en la normalidad.

Teorema Central del Límite

Enunciado clásico:

Sea $X_1, X_2, \dots, X_n$ una secuencia de variables aleatorias independientes e idénticamente distribuidas, con media μ y varianza σ^2 .

Entonces, la variable estandarizada:

$$Z_n = \frac{\frac{1}{n} \sum_{i=1}^n X_i - \mu}{\sigma / \sqrt{n}}$$

converge en distribución a una normal estándar $N(0,1)$ cuando $n \rightarrow \infty$.

Interpretación:

- Si sumamos muchas **variables aleatorias**, la distribución de la suma (o del promedio) **tiende a parecerse a una normal**, sin importar la forma original de las variables.
- La **normalidad aparece como un fenómeno emergente**.

Visualización

- Con pocas sumas, el histograma sigue la forma original de las variables.
- Al aumentar el número de sumas, aparece la campana de Gauss.
- Esto es lo que vimos en el ejercicio de:
 - Suma de 2 variables → forma irregular.
 - Suma de 5 variables → más simétrica.
 - Suma de 30 variables → casi normal.

Aplicaciones prácticas del TCL

1) Estadística inferencial:

Justifica el uso de la **normal** para construir intervalos de confianza y pruebas de hipótesis.

2) Control de calidad y manufactura:

Sumas de pequeñas variaciones generan distribución normal de errores.

3) Finanzas y riesgos:

Rendimiento total de una cartera como suma de rendimientos individuales.

4) Machine Learning y Big Data:

Promedios y agregaciones de grandes volúmenes de datos tienden a comportarse de forma normal.

Modelos probabilísticos aplicados a predicción y machine learning.

1. ¿Qué es un modelo probabilístico?

Un **modelo probabilístico** es aquel que:

- Describe **incertidumbre** mediante **distribuciones de probabilidad**.
- Predice resultados **no deterministas**, asignando **probabilidades** en lugar de valores fijos.
- Ejemplos:
 - Predicción de **lluvia**: 80% de probabilidad mañana.
 - **Diagnóstico médico**: 95% de probabilidad de ser positivo según los síntomas.

Matemáticamente:

- Se define por un **conjunto de variables aleatorias** y sus **distribuciones**.
- Puede considerar **dependencias** (ej.: modelos bayesianos) o **independencia** (ej.: Naive Bayes).

2. Tipos de Modelos Probabilísticos en Predicción

1. Modelos de Clasificación Probabilística

- Predicen **probabilidades de pertenecer a cada clase**.
- Ejemplos:
 - **Naive Bayes** (asume independencia condicional).
 - **Regresión logística** (predice $P(Y=1|X)$).
- **Aplicación:**
 - Spam vs no spam, diagnóstico médico, fraude bancario.

2. Modelos de Regresión Probabilística

- Predicen **una variable numérica** considerando **incertidumbre**.
- Ejemplos:
 - **Regresión lineal con intervalo de confianza**.
 - **Gaussian Process Regression** (aprendizaje no paramétrico).
- **Aplicación:**
 - Predecir precios, series temporales de demanda, sensores IoT.

3. Modelos Generativos

- Describen **cómo se generan los datos** desde una distribución.
- Permiten **simular nuevos datos y clasificar observaciones**.
- Ejemplos:
 - Modelos de mezcla de Gaussianas (GMM).
 - Redes Bayesianas.
- **Aplicación:**
 - Reconocimiento de voz, visión por computadora, imputación de datos faltantes.

3. Machine Learning y Probabilidad

En ML, la probabilidad se usa para:

- **Manejar incertidumbre:**
 - Las predicciones nunca son 100% seguras.
 - Ejemplo: “El modelo estima 70% de probabilidad de lluvia”.
- **Regularización y Bayes:**
 - Evitar sobreajuste usando **probabilidades a priori**.
- **Predicción de clases o valores:**
 - Clasificadores probabilísticos devuelven **scores** que permiten umbrales flexibles.

Ejemplo práctico (Naive Bayes):

1. Contamos **frecuencias de palabras en emails**.
2. Calculamos **probabilidad de spam dado el contenido**.
3. Clasificamos según la mayor probabilidad.

4. Visualización didáctica

- **Diagrama de flujo:**
 1. Datos → 2. Estimación de distribuciones → 3. Cálculo de probabilidades → 4. Predicción.
- **Ejemplo gráfico:**
 - Conjunto de puntos A (azules) y B (rojos).

- Un nuevo punto (verde) se clasifica según la **probabilidad más alta**.

5. Aplicaciones concretas en Machine Learning

- 1. Clasificación de texto:**
 - **Spam filtering**, análisis de sentimientos.
 - Modelo: **Naive Bayes**.
- 2. Predicción de riesgo financiero:**
 - Probabilidad de impago de créditos.
 - Modelo: **Regresión logística**.
- 3. Series temporales y pronósticos:**
 - Modelos ARIMA y bayesianos.
 - Predicen **con intervalos probabilísticos**.
- 4. Visión por computadora:**
 - Reconocimiento facial o de objetos.
 - Modelos **generativos probabilísticos** como GMM o redes bayesianas.

6. Conexión con los ejercicios previos

- Los **histogramas y el TCL** muestran **cómo modelar distribuciones de datos**.
- Ahora pasamos de **describir la incertidumbre** → a **usar la incertidumbre para predecir y clasificar**.